Formulation MDL pour le clustering incrémental à prototypes binaires

1. Notations

- L : longueur fixe de chaque instance binaire (ex. 8 bits).
- $N = \sum_j n_j$: nombre total d'instances insérées.
- Pour chaque cluster C_j :
  - n_j : nombre d'instances dans C_j.
  - s_j : longueur du préfixe spécifique (bits fixes) du prototype.
  - $w_j = L - s_j$: nombre de jokers ($*$) du suffixe.

2. Coût du modèle

On encode chaque prototype en ne stockant que ses s_j bits fixes :

$$L_{\text{modèle}} = \sum_j s_j$$

3. Coût des données

Une fois le prototype connu, chaque instance dans C_j encode ses w_j bits libres :

$$L_{\text{données}} = \sum_j n_j \times w_j$$

4. Coût d'assignation

Pour chaque instance, il faut coder l'appartenance à un cluster. Si $p_j = n_j/N$ est la fréquence de C_j, alors l'identifiant de cluster coûte $-\log_2 p_j$ bits. (théorie de l'information) D'où :

$$L_{\text{assign}} = \sum_j n_j \left[-\log_2(p_j)\right] = \sum_j n_j \log_2\Big(\tfrac{N}{n_j}\Big).$$

Pourquoi inclure L_{assign} ?

— Sans ce terme, créer un prototype par instance donnerait $L_{\text{modèle}} + L_{\text{données}} = 0$, conduisant à N clusters de taille 1.
— L_{assign} pénalise la fragmentation :

$$\text{créer un cluster seul coûte } n_j \log_2(N/n_j) \quad \text{par instance,}$$

favorisant le rattachement aux clusters déjà gros.

5. Critère MDL total

On somme les trois contributions :

$$\boxed{L_{\text{total}} = L_{\text{modèle}} + L_{\text{données}} + L_{\text{assign}} = \sum_j s_j \; + \; \sum_j n_j \, w_j \; + \; \sum_j n_j \, \log_2\!\Big(\tfrac{N}{n_j}\Big)}$$

6. Choix incrémental

Lors de l'arrivée d'une nouvelle instance, on simule :
— la généralisation d'un prototype existant (suffixe en jokers),
— ou la création d'un nouveau prototype.
On choisit l'opération qui minimise l'augmentation de L_{total}.